DỰ BÁO PM2.5 TRƯỚC 1 GIỜ

Tại các trạm quan trắc Bắc Kinh

Báo cáo giữa kỳ môn Máy học

NhomXX • Thành viên / MSSV / giảng viên: [CẦN BỔ SUNG]

Minh chứng đến T12 • Trọng tâm T09/T10 • Chưa T13/test

49 hồ sơ log ≠ 49 model độc lập

NHÓM VÀ TIẾN ĐỘ THỰC TẾ

BẢN NHÁP

NhomXX

Đã có minh chứng	Đang làm	Chưa làm
T01–T08: dữ liệu/EDA/pipeline	MK01 + nhóm bổ sung thông tin	T13 test cuối / refit
T09/T10: baseline + 2model	MK02 sau MK01	T14 demo; T15/T16 cuối kỳ
T11/T12: CV + A/B/C	Xác nhận phân công/đóng góp	Chưa có weights triển khai

Tên–MSSV, số nhóm, việc từng người, minh chứng và rubric: [CẦN BỔ SUNG]

Không suy đóng góp từ Git author hoặc số commit.

Nguồn: project_plan.md; metadata chưa có xác nhận nhóm

BÀI TOÁN: INPUT ĐẾN t → OUTPUT ĐÚNG t+1

Input: số đo tại t + station/wd + lịch t+1 biết trước

B thêm lag/rolling PM2.5 cùng trạm, không tương lai

Output: một nồng độ PM2.5(s,t+1), đơn vị μg/m³

RQ1	RQ2	RQ3
ML hơn persistence?	Lag/rolling và selection giúp thế nào?	Sai số theo trạm/mùa/nồng độ?
T09/T10 có validation thật	T12 ablation cố định params	Chưa có đánh giá test cuối

Nguồn: problem_definition.md; B01/B02; horizon=1h, cùng station

CRISP-DM LÀ VÒNG LẶP, KHÔNG CHỈ DANH SÁCH TASK

BẢN NHÁP
NhomXX

Hiểu bài toán

T02: RQ, Input/Output

Hiểu dữ liệu

T03/T04/T06: audit + EDA

Chuẩn bị dữ liệu

T05/T07/T08: causal pipeline

Mô hình hóa

T09–T12: baseline/CV/A-B-C

Đánh giá

Validation phát triển; test khóa

Triển khai

MK01/MK02; T14 chưa làm

Giả thuyết → ngân sách → chạy → nhận xét → giữ/sửa/thử tiếp

Nguồn S02 (IBM); mapping project_plan.md

DỮ LIỆU UCI 501: NHIỀU TRẠM, THEO GIỜ

12 trạm • 420.768 dòng • 18 cột raw

2013-03-01 → 2017-02-28

PRSA2017, không phải Beijing PM2.5 một trạm

Nhóm biến	Đơn vị/vai trò
PM2.5/PM10/SO2/NO2/CO/O3	µg/m³; tại t là input, PM2.5 t+1 là nhãn
TEMP/DEWP; PRES; RAIN; WSPM	°C; hPa; mm; m/s
station/wd; thời gian; No	Categorical; tạo timestamp; loại No khỏi feature

TARGET VÀ SPLIT: KHÓA TEST, KHÔNG RANDOM K-FOLD

Tập	Primary N	Ranh giới target
Train	204.865	<2015-03-01
Validation	102.479	[2015-03-01,2016-03-01)
Test — khóa	101.836 (audit)	≥2016-03-01; chưa metric

Join đúng (station,t+1h), không shift qua giờ khuyết; không impute target.

3 expanding folds trong train, purge nhãn tại origin đầu đánh giá.

Fit lại mọi bước học dữ liệu ở train/fold-train; same IDs khi so model.

EDA TRAIN → QUYẾT ĐỊNH XỬ LÝ

BẢN NHÁP

NhomXX



CO thiếu 6,74%

PM2.5(t) thiếu 1.112 origins

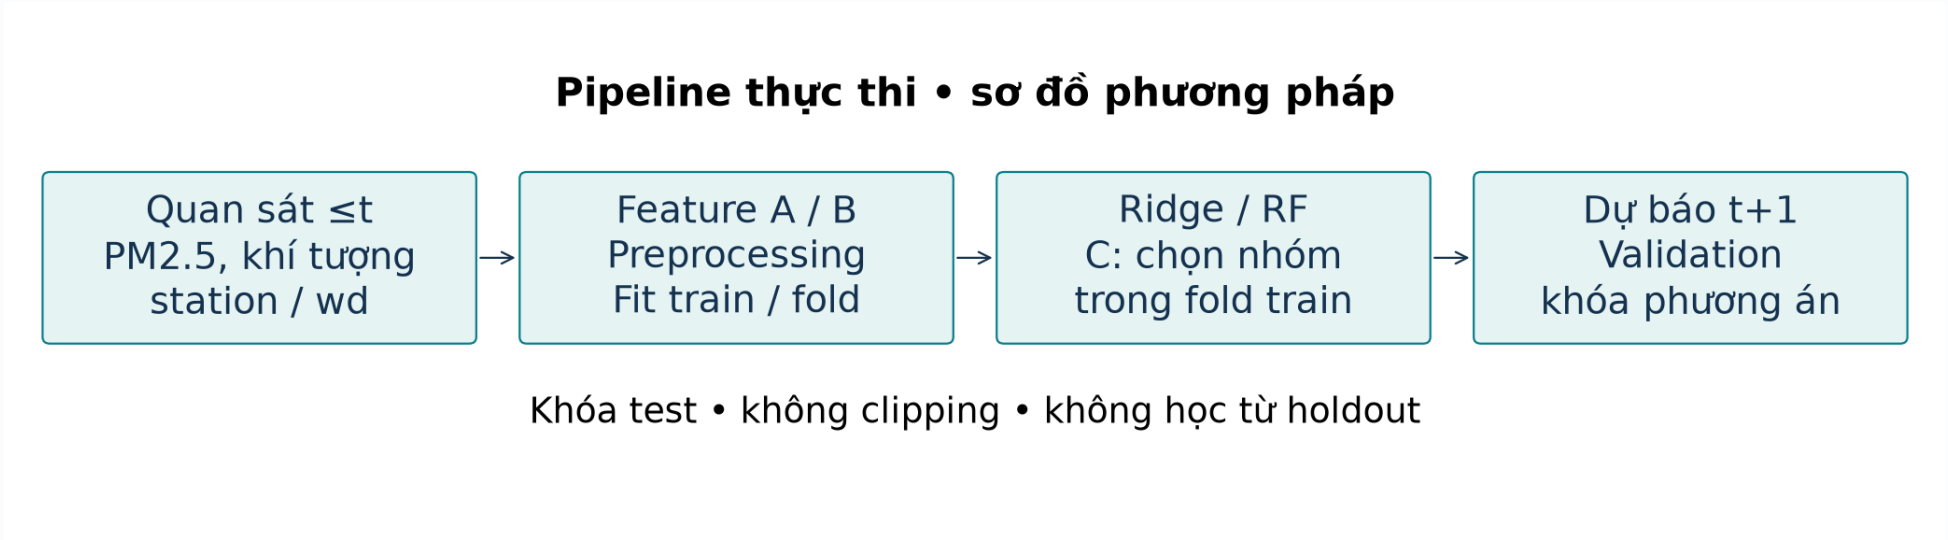
PM2.5 median61; max844 µg/m³

Giữ đợt cao; không xóa IQR

Khác biệt trạm + chu kỳ thời gian

→ median/indicator, scale Ridge, A/B causal

PIPELINE VÀ A/B/C: KHÁC NHAU Ở ĐÂU?



A20: số đo t + station/wd + lịch t+1

B33: A + lag1/3/6/12/24h + rolling mean/std3/6/12/24h

C: subset nhóm từ B; OHE và indicator giữ cùng source

Ridge scale, RF không scale; identity output, không clipping

PERSISTENCE LÀ MỐC MẠNH CHO t+1

Có PM2.5(s,t): dự báo đúng giá trị đó

Nếu thiếu: lịch sử cùng trạm tuổi≤24h → median trạm/global từ train

Không lấy tương lai; giữ ID và log nguồn/tỷ lệ fallback

MAE (µg/m³)	RMSE (µg/m³)	R^2
9,736617	19,240919	0,944804

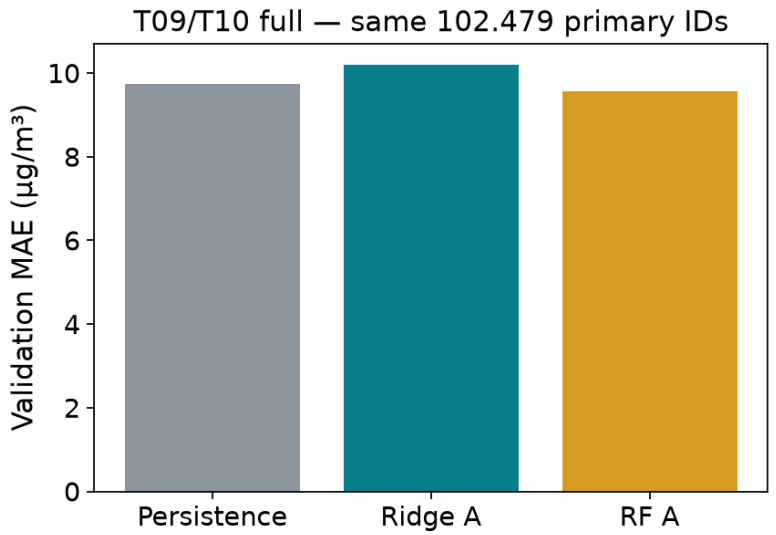
Primary có số đo t nên không fallback; operational ghi riêng.

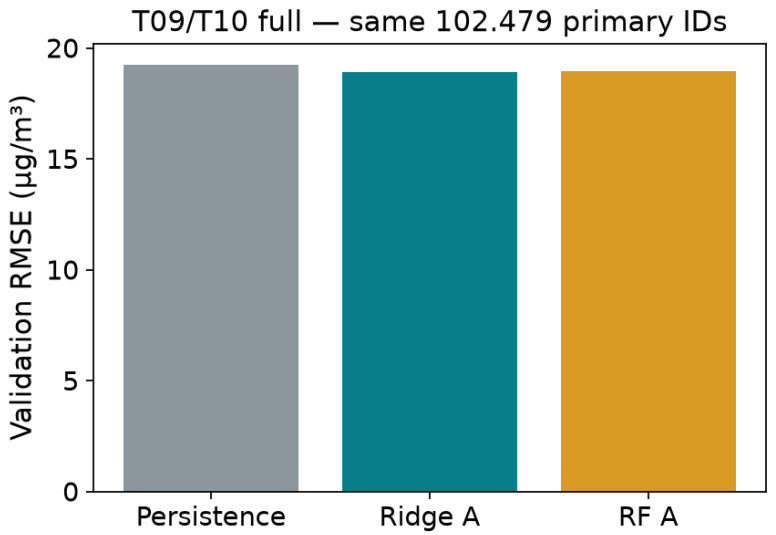
Không trộn cohorts hoặc dùng smoke làm score chính.

T10: RF CẢI THIỆN NHẸ MAE, RIDGE TỐT RMSE

BẢN NHÁP

NhomXX





RF A: MAE9,561488

≈giảm1,80% so baseline

Ridge A: MAE10,200433

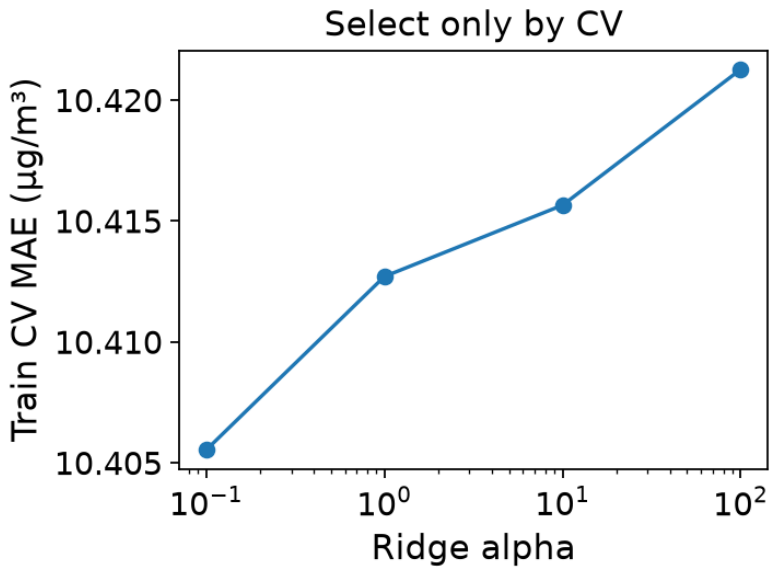
nhưng RMSE18,907140 thấp nhất vòng đầu

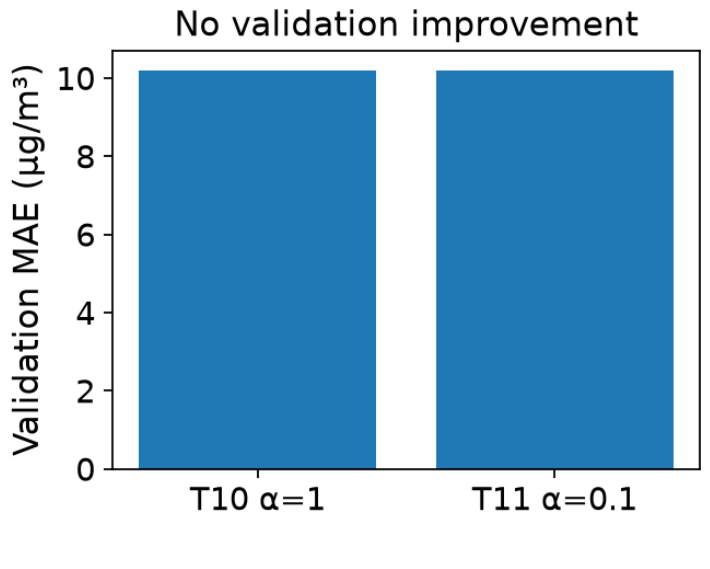
Config cố định	Chi phí fit T10	Giới hạn
Ridge alpha1; RF80/depth12/leaf2/seed42/job1	Ridge≈2,96s; RF≈161,22s	Một split; Ridge có2685 dự báo âm, giữ identity

T11: CV THẮNG NHỎ, VALIDATION CHƯA CẢI THIỆN

BẢN NHÁP

NhomXX





Alpha {0.1,1,10,100}

3 expanding folds train

CV chọn alpha0.1

Validation MAE10,200529

T10:10,200433 → hơi kém

Giữ kết quả, không sweep tiếp

Pooled MAE dùng chọn; mean/std fold chỉ mô tả biến thiên, không confidence interval.

T12 / RQ2: HISTORY VÀ SELECTION GIÚP RIDGE

BẢN NHÁP

NhomXX

Ridge A/B/C	Chiều model	Validation MAE	RMSE
A (reuse T11)	65	10,200529	18,907198
B (+history)	91	9,968755	18,467071
C (12nhóm CV)	24	9,903377	18,501063

C giảm MAE nhẹ so B nhưng RMSE tăng nhẹ; không thắng mọi metric.

RF A T10 vẫn tốt nhất pool MAE9,561488 → khóa công thức RF A.

Chưa weights triển khai, refit train+validation hoặc test/T13.

VÒNG THỬ → NHẬN XÉT → QUYẾT ĐỊNH

Vòng	Quan sát	Quyết định
T09	Persistence mạnh ở horizon1h	Giữ đối chứng cùng IDs/fallback causal
T10	RF hơn nhẹ MAE; Ridge kém MAE	Giữ cả tốt/kém và trade-off RMSE/cost
T11	Alpha CV tốt, val chưa cải thiện	Không tăng budget sau score
T12	C ít chiều +MAE tốt hơn B	Chưa thắng RF; freeze theo criterion đã chốt

Validation dùng nhiều lần; CV không nested, feature tương quan → chưa là kết luận test độc lập.

KHÓ KHĂN, PHẦN CÒN LẠI VÀ ĐÓNG GÓP

Khó khăn: missing, đợt ô nhiễm cao, leakage thời gian, RAM/cost.

Cách làm: giữ raw, pipeline train-only, purge, budget hữu hạn, log cả kém.

MK02: kiểm/gói, không huấn luyện thêm hoặc nộp Classroom.

T13–T16: chỉ khi được giao, refit/test → demo → hồ sơ/kiểm cuối.

Tên–MSSV, công việc, minh chứng/đóng góp và hạn nộp: [CẦN BỔ SUNG]

Chưa benchmark máy sạch hoặc có serialized weights để inference.

Nguồn: project_plan/midterm_plan; không tự đặt deadline/phân công

NGUỒN, AI DISCLOSURE VÀ VIỆC NHÓM CẦN ĐIỀN

BẢN NHÁP

NhomXX

S01 Chen(2017), UCI501 • DOI10.24432/C5RK5G • CC BY4.0

S02 IBM CRISP-DM; S03/S04 scikit-learn Ridge/RandomForest

Số liệu riêng: audit/EDA và predictions/log của repo, không mượn metric ngoài

Codex hỗ trợ mã, chạy/kiểm đã giao, tổng hợp và tạo tài liệu; nhóm tự kiểm và chịu trách nhiệm

[CẦN BỔ SUNG]: nhóm, thành viên, đóng góp, rubric/yêu cầu riêng, deadline

BẢN NHÁP — CHƯA SẴN SÀNG NỘP • Chưa mở test